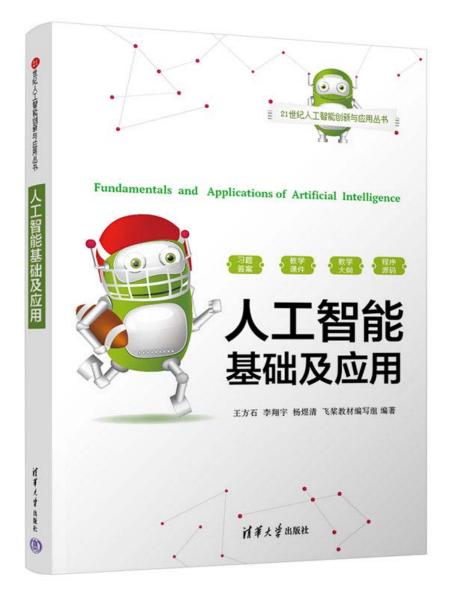
# 人工智能基础



# 北京交通大学 软件学院 王方石

Email: fshwang@bjtu.edu.cn

# 第2章 知识表示与知识图谱

- 2.1 知识的概述
- 2.2 知识表示的方法
- 2.3 产生式表示法
- 2.4 状态空间表示法
- 2.5 知识图谱

# 本章学习目标

- ◆了解知识的定义、特性、分类。
- ◆了解知识表示方法的分类。
- ◆了解知识的产生式表示法。
- ◆掌握状态空间表示法。
- ◆了解知识图谱的定义、表示、发展历史。
- ◆了解典型的知识图谱和知识图谱的应用。

#### 2.1 知识的概述

- ◆ 知识是智能的基础。
- ◆ 为了使计算机具有智能,能模拟人类的智能行为,就必须使它具有知识。
- ◆ 在人工智能领域中,"知识就是力量"依然有效。
- ◆ 人类的知识需要用适当的形式表示出来,才能存储到计算机中,并 被运用。
- ◆ 知识表示是人工智能领域中一个十分重要的研究课题。

### 2.1.1 知识的定义

- 至今,对于知识还没有一个统一而明确的界定。比较有代表性的定义如下:
  - (1) 费根鲍姆(Feigenbaum)说:知识是经过裁剪、塑造、解释、选择和转换了的信息。
  - (2) 伯恩斯坦(Bernstein)说: 知识由特定领域的描述、关系和过程组成。
  - (3) 海叶斯—罗斯(Heyes-Roth)说:知识=事实+信念+启发式。
- 总之,知识是人类在长期的生活、社会实践及科学实验中经过总结、提升与凝练的对客观世界(包括人类自身)的认识和经验,也包括对事实和信息的描述或在教育和实践中获得的技能。

#### 2.1.2 知识的特性

(1) 相对正确性。随着条件和环境的改变,原本正确的知识在不同的条件和环境下可能就不正确了。

例如,"水的沸点是 **100℃**",但前提是在一个标准大气压的环境下,若大气压强变了,则水的沸点就会发生变化,不再是**100℃**,大气压强越高,水的沸点越高,反之就越低。

(2) 不确定性。知识的不确定性是指知识有时不能被完全确定是"真"还是 "假",在"真"与"假"之间还存在许多中间可能性。

例如,如果某人眼睛发黄,则他得肝炎了。只能说"如果某人眼睛发黄,则他有可能得肝炎了"。

#### 2.1.3 知识的分类

#### 按知识的作用,可大致分为两类:

- (1) 陈述性知识(descriptive knowledge,或描述性知识),是表示对象及概念的特征及其相互关系的知识,以及问题求解状况的知识,它描述的是"做什么"的知识,即一般性事实,故也称为事实性知识。
  - ▶如: "煤是黑色的", "北京是中国的首都"。
  - ▶ 事实性知识是显式表示的,用符号代表概念、命题与原理,是相对静态的。
- (2) 过程性知识(procedural knowledge,或程序性知识)表示的是问题求解控制策略,描述的是"如何做"的知识,即做某件事的过程。
  - ▶ 过程性知识一般利用算法进行描述,用一段计算机程序来实现。
  - ▶ 过程性知识是**隐含在程序中**的,是相对**动态**的。

#### 2.2 知识表示的方法

- ◆ 知识表示(knowledge representation) 就是将人类知识符号化,并输入给计算机的过程和方法。
- ◆ 知识表示**研究的是:** 用计算机表示知识的方法和技术,它是数据结构与系统控制结构的统一。
- ◆ 知识表示的**目的**:要解决人类知识在计算机中的表示与存储的问题。
- ◆ 知识表示可以是一种符号描述、是某种约定,也可以是某种数据结构。
- ◆ 知识分为两类: 陈述性知识、过程性知识。
- ◆ 从知识的运用角度,可将知识表示方法粗略地分为两大类:
  - > 陈述性知识表示
  - > 过程性知识表示

#### 陈述性知识表示

- ◆ **陈述性知识表示**用于描述陈述性知识,即描述"是什么",而不用描述"怎么做"。
- ◆ 该方法注重对事物有关知识的**静态描述**,强调事物所涉及的对象是什么,关注于事物的属性及 其相互关系,涉及的知识细节少,抽象程度高。
- ◆ 该方法是对知识的一种**显式表达**形式,对于知识的使用和推理,则是通过控制策略或推理机制 来决定的。
- ◆ 在采用陈述性知识表示方法描述知识的系统中,**知识的表示和知识的运用一般是分开的**。
- ◆ 优点:
  - ▶ 可理解性好,表示形式简洁、清晰、易懂;
  - ▶ 易于修改,一个小的改变不会影响全局,不会引起大的改变;
  - ▶ 可独立使用,这种知识表示出来后,可用于不同目的;
  - ▶ 易于扩充,这种知识模块性好,扩充后对原有模块没有影响。
- ◆ 缺点:将知识与控制分开,求解问题的执行效率低。

#### 过程性知识表示

- ◆ 过程就是事实的一些客观规律。
- ◆ **过程性知识表示方法**表达的是如何求解问题,知识的表示形式就是程序。
- ◆ 在过程性知识表示方法中,既要描述表示事物客观规律的知识,还要描述表示控制规则和控制结构的知识,告诉计算机"怎么做"。
- ◆ 该方法着重于描述知识的**动态过程**,将求解问题的主要步骤表示为若干个过程,每一个过程就是一段程序,是对知识的一种**隐式表达**形式。
- ◆ 知识的表示和知识的运用一般是不分开的,表示就寓于运用之中,它适合于知识表示与求解结合非常紧密的这一类问题。

#### 过程性知识表示

◆ 优点: 执行效率高。

知识是用程序表示的,知识库与推理机完全合为一体,即知识与控制融合在一起。

#### ◆ 缺点:

- ▶可理解性较差,采用隐式表达形式,形式复杂、不直观,不易理解;
- >不易于扩充,这种知识模块性差,难以添加新知识和扩充新的功能;
- ▶不易于修改,想要修改现有知识而不影响其他知识的完整性,比较困难,容易出错。

#### 2.3 产生式规则表示法

- ◆ "产生式(production)" 意思是能够根据已知条件产生新知识的式子。
- ◆ 这些式子往往以规则的形式描述知识,因此**产生式**也称作"**产生式规则**";
- ◆ 产生式表示法也称为产生式规则表示法。
- ◆ 它属于**符号主义流派**的知识表示方法。
- ◆ 1960s-1970s,产生式表示法是使用最广泛的一种主流知识表示方法,尤其是在许多成功的专家系统中。例如,DENDRAL系统,MYCIN系统,PROSPECTOR系统。
- ◆ 随后,产生式表示法被应用于**形式语言学**、计算语言学中的**句法分析器、 机器翻译**等。

#### 2.3.1 产生式

- ◆ 产生式又称为规则或产生式规则。
- ◆ 产生式表示方法通常用于表示**事实、规则**以及它们的**不确定性度量**。
- ◆ 既有利于表示**陈述性知识**,又有利于表示**过程性知识**。
- ◆ 产生式表示包括**事实的表示**和规则的表示。
- ◆ 有许多知识本身就是事实描述性的, 事实可看成是一个对象的某属性的值或是多个对象之间关系的陈述句。对象的某属性值或对象之间的关系可以是一个词, 不一定是数字。
- ◆ 事实又分为**确定性事实**和**不确定性事实**。

# 事实的产生式表示

#### (1) 确定性事实的产生式表示

确定性事实一般采用三元组表示,有两种形式:

- ◆ 属性型确定性事实: 描述一个对象的某种属性,形式为 (对象,属性,值)
  - 如, "李丽的年龄是30岁"表示为(李丽,年龄,30)

- ◆ **关系型确定性事实**: 描述两个对象之间的关系,形式为 (对象1,对象2,关系)
  - 如,"李丽和王军是朋友"表示为(李丽,王军,朋友),此处,关系就是一个词,而不是数字。

# 事实的产生式表示

#### (2) 不确定性事实的产生式表示

不确定性事实可以用一个不确定度量值(**0**,**1**)表示其不确定程度,即置信度或可信度,一般采用四元组表示,也有两种形式:

◆ **属性型不确定性事实**: 描述一个对象的某种属性,形式为 (对象,属性,值,置信度)

例如"李丽的年龄很可能是30岁"表示为(李丽,年龄,30,0.85),其中置信度 0.85表示"很可能"。

◆ 关系型不确定性事实: 描述两个对象之间的关系, 形式为 (对象1, 对象2, 关系, 置信度)

例如"李丽和王军不太可能是朋友"表示为(李丽,王军,朋友,0.15),此处的置信度0.15表示"不太可能"。

### 规则的产生式表示

- ◆ 除了描述**事实**,产生式还可以描述规则。
- ◆ 规则用于表示有关问题领域中事物之间的**因果关系**,在产生式表示法中 **将规则作为知识的单位**。
- ◆ 在人类的认知中,很多知识单元之间都存在着因果关系,这些因果关系可以转化为前提和结论,非常便于用产生式表示。
- ◆ 规则可分为确定性规则和不确定性规则。

# 规则的产生式表示

#### (1) 确定性规则的产生式表示

- ◆ 确定性规则的产生式表示的基本形式是
  IF condition THEN action 或者 condition → action
  其中condition称为条件或前件或前提, action 称为动作或后件或结论。
- ◆ 语义含义是:如果condition所表示的条件被满足,则可得到action所表示的结论或者执行action所表示的动作,即action是由condition来触发的。
- ◆ 例如,有如下规则:
  - ➤ IF (天下雨 / 外出) THEN (带伞 / 带雨衣)。
  - ▶ 小刚很聪明 / 小刚学习很勤奋→小刚的学习成绩很好;
  - ▶ 小刚的学习成绩很好→小刚被重点大学录取。

# 规则的产生式表示

#### (2) 不确定性规则的产生式表示

◆ 若规则是不确定的,则需增加置信度的度量值。不确定性规则的产生式表示的基本形式是

IF condition THEN action (置信度)

或者 condition → action (置信度)

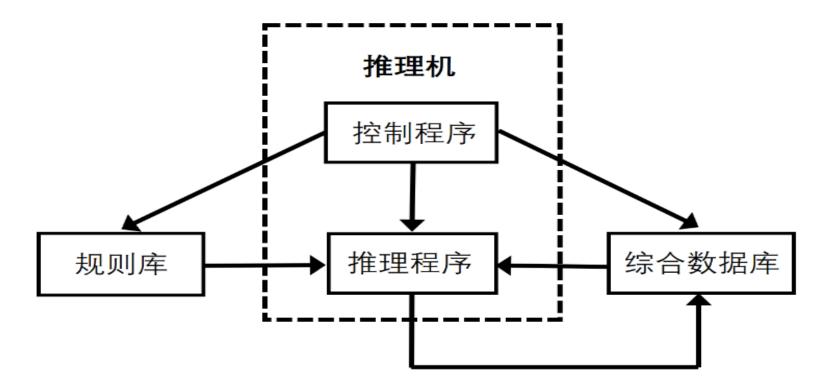
例如,有一条产生式为:发烧呕吐 ∧ 出现黄疸 → 肝炎(0.7)

# Typical Methods of Knowledge Representation

- ◆ First-order logic representation 一阶逻辑表示(Prolog语言)-----符号主义
- ◆ Production system 产生式系统 ---------------------------------符号主义
- ◆ Frame-based System 基于框架的系统(框架理论,明斯基)-----符号主义
- ◆ Semantic Network 语义网络(LISP语言)-------符号主义
- ◆ Bayesian Network 贝叶斯网络-------符号主义
- ◆ Ontology 本体
- 最早由google公司于2012年提出,用于其搜索引擎,目的是增强信息检索能力。

# 2.3.2 产生式系统

- ◆一个产生式系统的基本结构由规则库(production rules base)、**综合数据库**(global database)和**控制系统** (control system)三部分组成。
- ◆综合数据库和规则库共同组成了知识库。
- ◆ 控制系统又称为推理机,包括控制程序和推理程序两部分。



### 2.3.2 产生式系统

#### 1. 综合数据库

综合数据库又称为**事实库**,是产生式系统所使用的主要数据结构,其中存放问题的初始状态、输入的已知事实、推理过程中得到的中间结果及最终结论等信息。

#### 2. 规则库

产生式规则用于描述与所求解问题相关的领域知识,规则库就是所有这些产生式规则的集合,其中包含了将问题从初始状态转换成目标状态所需的所有规则。

#### 3. 推理机

推理机是一组**规则解释程序**,包括**控制策略**和**推理方式**。推理机协同规则库与综合数据库,控制问题求解过程的推理路线,负责整个产生式系统的运行,实现对问题的求解。

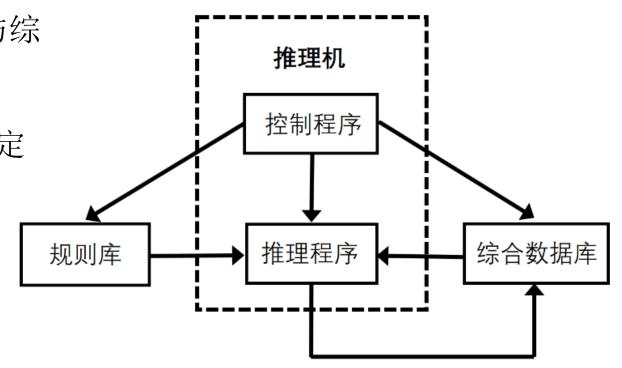
# 推理机的主要工作内容

- (1) 选择推理规则:按照一定策略,将其前件与综合数据库中的已知事实进行匹配。
- (2) 消解冲突,若找到多个匹配规则,则按一定的策略选出一个来执行。
- (3) 进行推理。
- (4) 判断是否终止推理。

#### 例如,推理过程:

小刚很聪明△小刚学习很勤奋 → 小刚的学习成绩很好;

小刚的学习成绩很好 ∧ 发挥正常 → 小刚被重点大学录取



#### 2.3.3 产生式表示法的特点

- ◆ 产生式表示法的主要优点
  - (1)格式单一, 计算简单。
  - (2)模块化,便于知识的操作和管理。
  - (3)形式自然,便于理解、推理和解释。
  - (4)表达较全面,应用广泛。
- ◆ 产生式表示法的主要缺点
  - (1)求解效率不高。
  - (2)无法表示具有结构关系的知识。

- ◆ 状态空间(state space)表示法是人工智能中最基本的形式化方法, 是其他形式化方法和问题求解技术的出发点。
- ◆ 状态(state)就是用来描述在问题求解过程中某一个时刻进展情况等陈 述性知识的一组变量或数组,是某种结构的符号或数据。
- ◆ 状态是一组变量 $q_0$ ,  $q_1$ ,  $q_2$ , ...,  $q_n$  的有序集合, 其形式如下:

$$Q=\{ q_0, q_1, q_2, \dots, q_n \}$$

- 其中,每个元素 $q_i$ 称为一个状态变量。
- ◆ 状态的表示还可以根据具体应用,采取合适的数据结构,如符号、字符 串、多维数组、树和图等。

- ◆操作也称为运算,用来表示引起状态变化的过程性知识的一组关系或函数,它会引起状态中的某些分量发生改变,从而使问题由一个具体状态转换到另一个具体状态。
- ◆ 操作可以是一个动作(如棋子的移动)、过程、规则、数学算子等,表 示状态之间存在的关系。
- ◆ 用于表示操作的符号,称为操作符(operator)或操作算子、运算符。
- ◆ 状态空间是采用状态变量和操作符号表示系统或问题的有关知识的符号体系。

- ◆ 问题的**状态空间**是一个表示该问题**全部可能状态**及其**相互关系**的集合,常用一个四元组( $S,O,S_0,G$ )来表示,其中:
  - ➤ S 为问题的**状态集合**;
  - ▶ O 为操作符的集合;
  - $\triangleright$   $S_0$  是问题的初始状态,是S的一个非空真子集,即 $S_0 \subset S$ ;
  - ightharpoonup G为问题的目标状态,它既可以是若干具体状态,也可以是满足某些性质的路径信息描述, $G \subset S$ 。

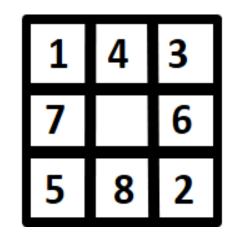
- ◆ 状态空间通常用**有向图**来表示,其中,**节点**表示问题的**状态**,节点之间的**有向边** 表示引起状态变换的**操作**,有时边上还赋有**权值**,表示变换所需的**代价**。
- ◆ 在状态空间中, 求解一个问题就是从初始状态出发, 不断运用可使用的操作, 在 满足约束的条件下达到目标状态。
- ◆ 问题的解可能是图中的一个状态,也可能是从初始状态到某个目标状态的一条路径,还可能是达到目标所花费的代价。
- ◆ 下图中,问题的解便是一条从节点  $S_0$  到节点 G 的路径,它是一个从初始状态到目标状态的有限的操作算子序列 $\{O_1, O_2, ...O_k\}$ ,称为求解路径。问题的解往往并不唯一。

$$S_0$$
  $O_1$   $O_2$   $O_3$   $O_4$   $O_6$   $O_6$   $O_7$   $O_8$   $O_9$   $O_9$ 

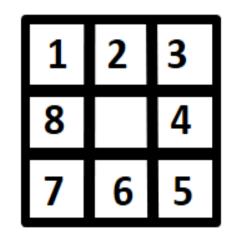
#### 例2.1 八数码问题

八数码问题又称为重排九宫问题。

#### 首先,需要定义八数码问题的状态集合。



(a) 初始状态



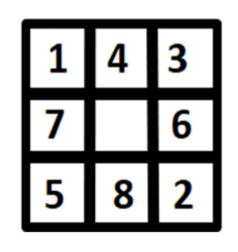
(b) 目标状态

- ◆ 八个数码的任何一种摆法就是一个**状态**。
- ◆ 八数码的所有摆法构成了状态集合S,它们构成了一个**状态空间**.
- ◆ 这个状态空间中可以有 9! 个状态。

### 例2.1 八数码问题

#### 然后,设计操作集合:

将移动空格作为操作,即在方格盘上移动数码等价于移动空格。



up: 将空格向上移, if 空格不在最上一行

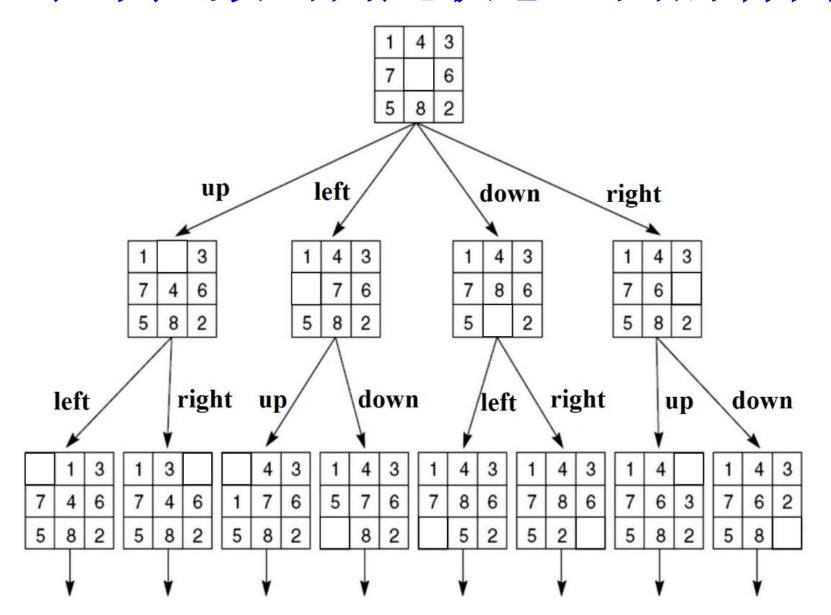
down:将空格向下移,if空格不在最下一行

lelt: 将空格向左移, if 空格不在最左一列

right: 将空格向右移, if 空格不在最右一列

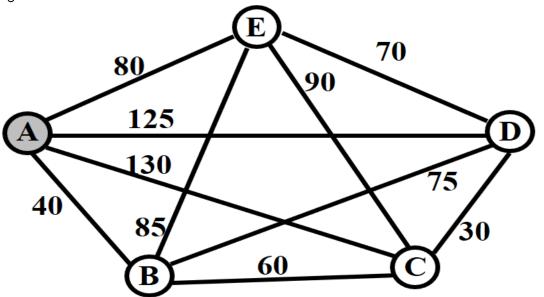
- ◆ 八数码问题的**解**就是一个使棋盘从初始状态变化到目标状态的数码牌 移动序列。
- ◆ 显然, 八数码问题的**解并不是唯一的**;
- ◆ 可以附加一些**约束条件**,例如要求找到一个移动数码牌次数最少的解。

### 表示八数码问题状态空间的有向图



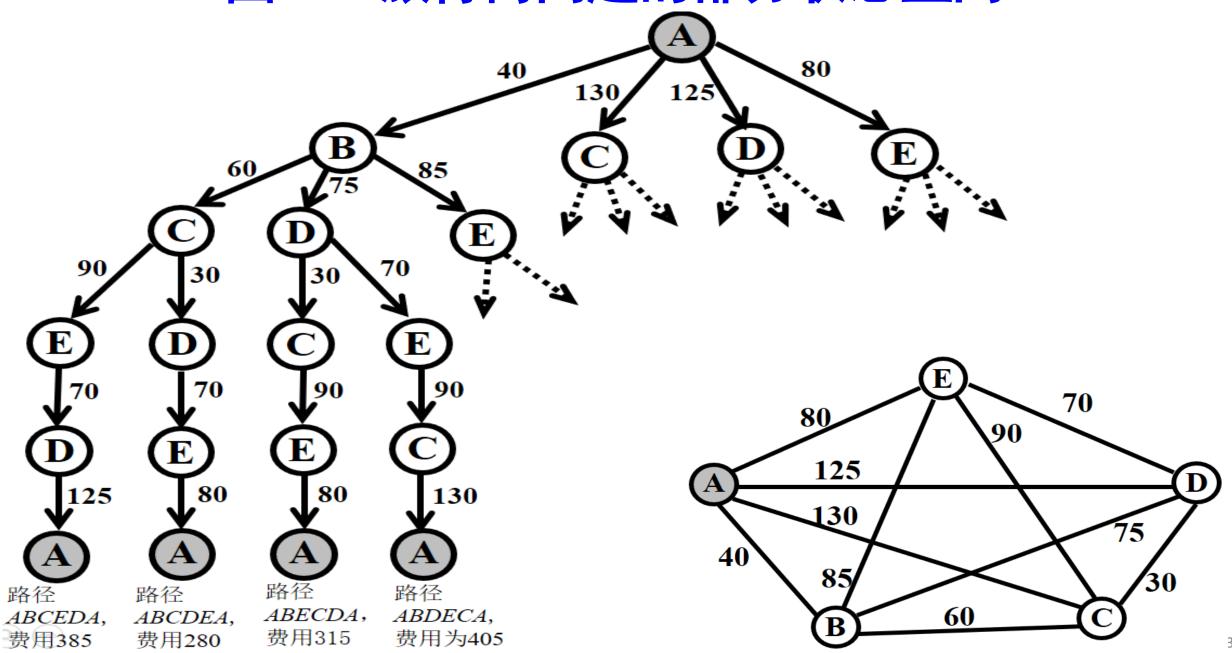
### 例2.2 旅行商问题

- ◆ 也称为**旅行推销员问题**。一个推销员要到N个城市去推销产品,已知每对城市之间的 距离,他从一个城市出发,访问所有城市后,回到出发地。
- ◆ 除了出发地,要求每个城市仅经过一次。
- ◆ 所要求解的问题是:应该如何设计一条行进路线,才能使得推销员**访问每座城市所经过的路径最短或者费用最少**?
- ◆ 旅行商问题实质是: 在一个带有权重的、含有N个节点的完全无向图中,找一个权值最小的哈密尔顿(Hamilton)回路。



- ◆ 对于大规模的问题,例如旅行商问题中有100个城市,要在有限时间内 画出其全部状态空间图,是不可能的。
- ◆ 对于**简单问题**,可以采用有向图**直接画出状态空间**。
- ◆ 对于大多数**复杂的问题**,根本**无法完全画出其状态空间**,此时只需清晰地定义状态变换的方式即可,如图**2.6**。

### 图2.6 旅行商问题的部分状态空间



# 2.5 知识图谱

- ◆ 符号主义知识表示方法经过不断完善,演变为知识图谱这一符合互联网 时代新需求的知识表示方法。
- ◆ 知识图谱是一种用**图结构**来描述知识及其之间关联关系的技术方法,旨 在利用知识工程理论建立大规模知识资源,**是语义Web技术在互联网大 数据时代的成功应用**。
- ◆ 知识图谱(Knowledge Graph)又称为科学知识图谱,知识图谱这一名词是谷歌公司于2012年5月17日首先提出的,其初衷是为了提高搜索引擎的能力,改善用户的搜索质量以及搜索体验,目标是构建一个可提供智能搜索服务的大型知识库。

### 2. 5. 1 知识图谱的定义

- ◆ 至今,知识图谱尚未有一个统一的定义。本质上,知识图谱是一种揭示客观世界中存在的**实体**(Entity)、概念(concept)及其之间各种关系的大规模语义网络,它以图结构表示知识,可理解为是一种描述语义知识的形式化框架,知识图谱就是这样一类知识表示和应用技术的总称。
- ◆ 知识图谱是一种**图结构的语义知识库**,组成单位是**实体、属性**和关系。
  - ▶ 节点表示实体(entity)或概念(concept)或属性值(attribute value)
  - ➤ 节点之间的边(edge)表示属性(attribute)或关系(relationship)
  - ▶ 边的方向表示关系的方向
  - ▶ 边上的标记表示属性名称或关系类型。

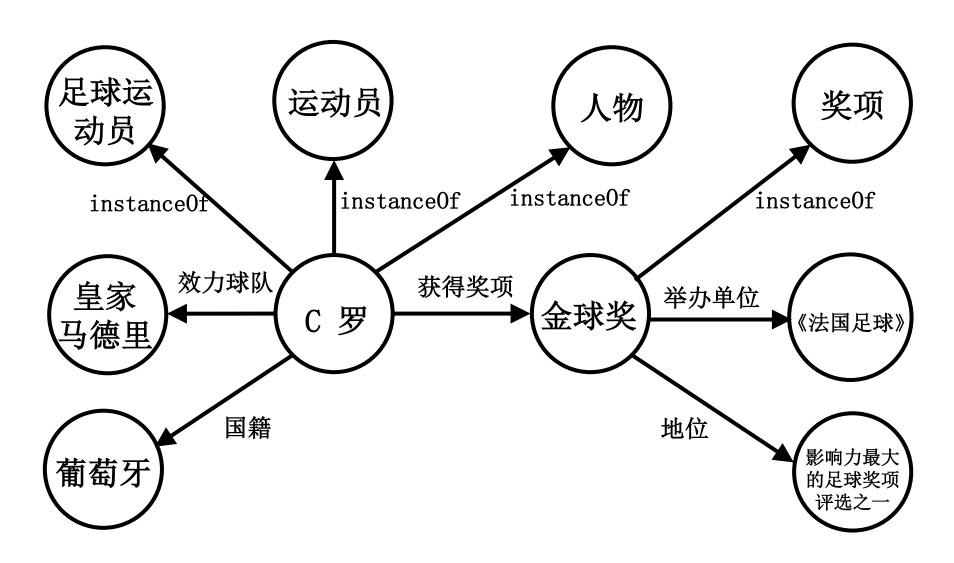
### 2. 5. 1 知识图谱的定义

- (1) 概念:也称为类别、类,是某一领域内具有相同性质的对象构成的集合。
  - > 大学领域的知识图谱中概念: 教师、学生和课程等;
  - ▶ 体育比赛领域中的概念:运动员、裁判员、教练、奖项等。
  - ▶ 概念主要用于表示集合、类别、对象类型、事物的种类。
- (2) **实体**(entity):有时也称为**实例**(instance)或**对象**(Object),实体是知识图谱中的最基本元素,是概念中的具体元素,它是**独立存在且可相互区别的客观事物**。例如,
  - ▶ "C罗"是"足球运动员"这一概念的一个实例,
  - ▶ "金球奖"是"奖项"这一概念的一个实例。

## 2. 5. 1 知识图谱的定义

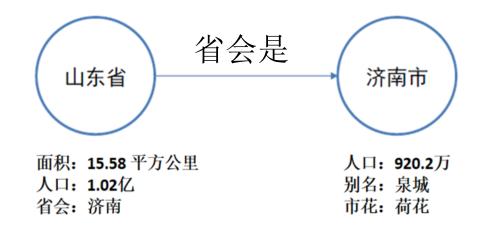
- (3) 属性: 描述实体或概念的特性或性质。属性值可能是一个实体、一个字符串或一个数值。例如:
  - ▶ 运动员的属性"国籍"的值是一个具体的国家(实例);
  - ➤ 属性"性别"的值是一个具体的字符串(male / female),
  - ▶ 属性"身高"的值则是一个具体的数值。
- (4) 关系: 是指概念之间或实体之间或概念与实例之间的联系, 例如:
  - ▶ "运动员"与"足球运动员"两个概念之间存在的父类与子类(subclassOf)的 层次关系;
  - ▶ "车轮"和"汽车"两个概念之间存在的部分与整体(partOf)关系;
  - ▶ "中国"与"北京"两个实体之间是"首都"关系;
  - ▶ "国家" (概念) 与"中国" (实体) 间是实例化 (instanceOf) 关系。

# 一个知识图谱示例



## 2. 5. 2 知识图谱的表示

- ◆每个实体或每个概念用一个全局唯一确定的ID 来标识, 称为标识符(identifier)。
- ◆概念和实体都是通过若干属性来刻画其内在特性。
- ◆概念之间常见的关系有父类与子类(subclassOf)关系、部分与整体(partOf)关系
- ◆ **实体之间**的关系多种多样,不同实体之间存在不同的关系。例如,
  - ▶ "山东省"和"济南市"两个实体分别有各自的属性,两者之间存在"省会是"的 关系:
  - ▶ "中国"和"北京"两个实体之间存在"首都是"的关系。
  - ▶ 所有实体和概念相互关联,形成复杂的"图"。





陆地面积:约960万平方公里

人口:约14.1175亿

面积:约1.641万平方公里

人口:约2188.6万

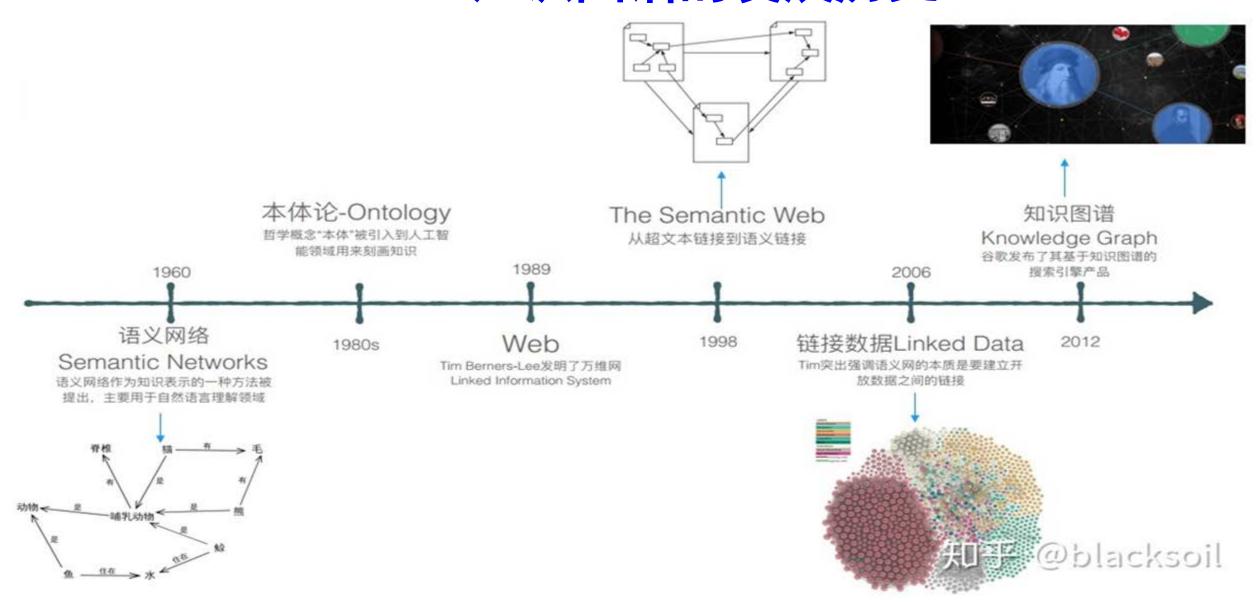
## 2. 5. 2 知识图谱的表示

- ◆知识图谱由多条知识组成,每条知识都表示为一个由主语(Subject)、谓词(Predicate)和宾语(Object)组成的三元组,即SPO三元组(Triples),它是知识图谱的一种通用表示方式。
- ◆与事实性知识的产生式表示方法类似,知识图谱也有两种形式:
- (1) 属性型联系:用"属性-值"对来描述一个实体具有某种内在属性,形式为 (实体,属性,属性值)
  - 例如,"北京市的面积是1.641万平方千米"表示为 (北京,面积,1.641万km2)
- (2) 关系型联系: 描述两个实例之间的关系, 形式为

(实体1,关系,实体2)

例如,"中国的首都是北京"表示为(中国,首都是,北京)

## 2.5.3 知识图谱的发展历史



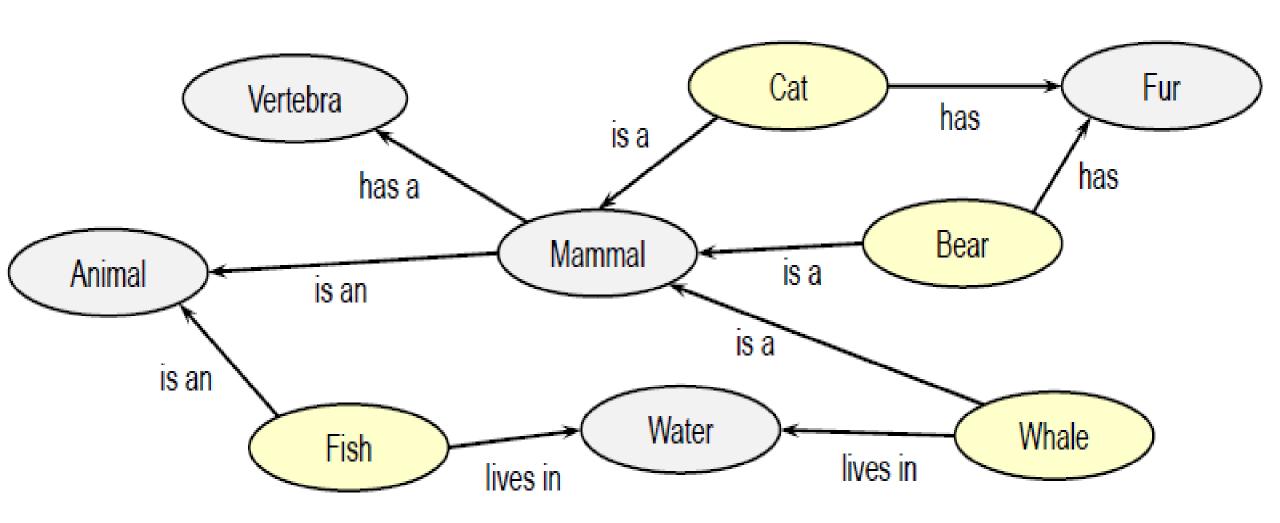
## 1. 语义网络知识表示(1960s)

- ◆ 1968年,认知科学家Allan Collins和Ross Quillian等人提出了**语义网络**(semantic network,**不是翻译为语义网**)的心理学模型。
- ◆ 随后, Quillian又将它用作人工智能中的一种知识表示方法
- ◆ 语义网络采用**有向图**来表示知识,其中**节点**表示**概念**(事件、事物), 边表示概念之间的**语义关系**。
- ◆ 1960年代, 剑桥大学的马斯特曼与其同事们还**将语义网络用于了机器翻译**。
- ◆ 1972年, 西蒙在他的自然语言理解系统中采用了语义网络表示法。

## 语义网络的特点

- ◆ **优点**:表达形式简单、直观、自然,因此容易理解和展示、相关概念容易 聚类。
- ◆ 缺点:
  - (1) 没有定义节点与边的值的标准,完全由用户自己定义;
  - (2) 无法区分概念节点和实体节点,如哺乳动物是个抽象概念,世界上 并没有一种动物名字就叫哺乳动物;
  - (3) 无法定义节点和边的标签;
  - (4) 难以融合多源数据,不便于知识的共享。
  - 上述缺点导致语义网络难以应用于实践。

# 语义网络知识表示的示例



### 2. 本体知识表示(1980s)

- ◆ 本体(Ontology)一词源于哲学领域,且一直以来存在着许多不同的用法。
- ◆ 本体论是研究"存在"的科学,即试图解释"存在"是什么,世间所有存在的共同特征是什么,本体论的基本元素是概念及概念间的关系。
- ◆ 1980年,"本体"概念被引入AI 领域中用于刻画知识,便产生了基于本体的知识表示方法,这种知识表示是一种"形式化的、对于共享概念体系的明确且详细的说明"。
- ◆ 本体**显式地**定义了领域中的**概念、关系和公理**(总是为真的陈述)及其之间的**联系**。
- ◆ AI 研究人员认为:可以创建基于本体的表示模型,从而进行特定类型的自动推理。
- ◆ 80年代出现了一批基于本体概念的知识库,例如,CYC和WordNet项目。

## 3. 语义万维网知识表示(1990—2006)

- ◆ 语义万维网(Semantic Web)也称为语义Web或语义网,与语义网络(semantic network)的技术理念完全不同。
- ◆ 两者最主要的区别: 语义网络知识表示与互联网无关,但语义万维网知识表示却是构建在万维网(world wide web)上的。
- ◆ 1963年,泰德·尼尔森(Ted Nelson)创造了"超文本(HyperText)"一词,其含义是用超链接的方法将各种不同空间的文字信息组织在一起的网状文本。
- ◆ 1969年,**因特网**诞生于美国,它的前身"阿帕网"(ARPAnet)是一个军用研究系统,后来才发展成为覆盖五大洲 150 多个国家的开放型全球计算机网络系统,也称为**互联**网。

## 3. 语义万维网知识表示(1990—2006)

- ◆ 1989年,英国计算机科学家蒂姆·伯纳斯·李(Lee)创新性地提出了将超文本用于因特网上的构想,并于1990年与同事 Robert Cailliau合作发明了万维网(world wide web)技术。
- ◆ 蒂姆·伯纳斯·李被誉为**万维网之父**,于2016年荣获图灵奖。
- ◆ 万维网诞生后,互联网上的网页数量迅速增加,网页之间相互关联形成网络,其中蕴含着大量知识。
- ◆ 但这种知识的**设计思想是面向人类阅读和理解的**,无法被计算机理解和计算。例如我们人类很容易知道两个网页内容是有关联的,但计算机很难理解网页的内容,更谈不上推理,获得新知识。
- ◆ 因此,蒂姆·伯纳斯·李又于1998年提出了"语义万维网(语义 Web)"的概念。

## 3. 语义万维网知识表示(1990—2006)

- ◆ **语义Web**旨在对互联网内容进行**语义化表示**,通过对网页进行语义定义,得到网页的语义信息,从而使计算机能够**理解、推理**互联网信息。
- ◆ 语义Web采用**图结构**的组织方式,图中的节点可以代表网页或客观存在的实体,超链接表示实体之间的关系。
- ◆ 相对于传统的网页互联网(即万维网),**语义Web的本质**是知识的互联网或事物的互联网(Web of Things)。
- ◆ 语义web是个宏大的构想,仅靠采用可扩展标记语言(extensible markup language, XML)标注web页面的数据内容是远远不够的,而是需要新的知识表示手段和方法。
- ◆ 在这样的背景下,科研工作者相继提出了"资源描述框架(Resource Description Framework,RDF)"和"网络本体语言(Web ontology language,OWL)"等面向 Web 的知识表示框架。

## **RDF**

- ◆ 每个RDF陈述都包含主语、谓词和宾语,简称SPO三元组,其中主语和宾语分别 表示两个资源,谓词表示两个资源间的关系。
  - > <Bob> <is a> <person>,
  - > <Bob> <is a friend of> <Alice>,
  - > <Bob> <is born on> <the 4th of July 1990>
- ◆ RDF的局限性:无法描述类别和属性的层级结构、包含关系。
- ◆ 万维网联盟(World Wide Web Consortium,简称W3C)又推出了RDF schema (RDFs),在RDF词汇的基础上扩展了一套数据建模词汇(如,class、subClassOf、type、Property、subPropertyOf等)来描述数据的模式层,可定义类的层次体系和属性体系,如类的继承。

## OWL (Web Ontology Language)

- ◆ RDFs的表达能力仍不够强大,在2001年,W3C又开发了OWL。
- ◆ OWL 主要在 RDFs 基础上**扩展了表示类和属性约束的表示能力**,以构建更为复杂 且完备的本体。如:
  - ➤ 复杂类表达(intersection, union 和 complement 等)
  - ➤ 属性约束 (existential quantification, universal quantification, has Value 等)
- ◆ OWL比RDF具有更强的表达能力和推理能力。 例如,OWL可以描述"中国所有湖泊"、"美国所有4000米以上的高山"这样的 类。

# 语义网络与语义Web的对比

- ◆ 相较于语义网络,语义Web更加注重于描述万维网中资源、数据之间的语义关系。
- ◆ W3C针对语义Web制定的标准解决了语义网络存在的不足:
  - ➤ RDF为节点和边的取值提供了统一标准,为多源数据的融合提供了便利;
  - ➤ RDFs/OWL解决了概念和对象的区分问题,即定义了Class 和 Object (也称作 Instance, Entity)。
- ◆ 这些标准从三个方面完善了语义Web:
  - ➤ 保证了语义Web的内容有准确的含义;
  - ➤ 保证了语义Web的内容可以被计算机理解并处理;
  - ➤ 计算机可从 Web 上整合各种网页中的内容信息。

## "弱语义"到"强语义"

- ◆ 从2001年到2006年,随着RDF和OWL标准的提出,语义Web技术突飞猛进,各种标准不断升级和复杂化,尤其是OWL的复杂程度很高,语义表达能力强大也导致了工程实现的难度大,构建知识库的成本越来越高。
- ◆ 期间,**语义Web**仍然沿袭着**符号主义的核心理念**,尝试建立完美的符号体系来涵 盖所有知识。
- ◆ 该阶段是从"弱语义"到"强语义"的探索。

## 4. 链接数据(2007年起)

- ◆ 随着语义Web体系结构的日益复杂,工程实现的难度变大,构建知识库的成本越来越高,语义Web的发展遇到了瓶颈。
- ◆ 另外,各个机构都独立开发了各自的语义Web,但各机构的知识库规模有限,不利于知识的共享。
- ◆ 2006年,Lee提出了**链接数据**(Linked Data)的设想,呼吁各个机构公开发布自己的数据源,并遵循一定的原则将数据汇聚起来,形成开放的数据网络。
- ◆ 其**目的**:将互联网上庞大的数据资源链接起来,构建一个计算机能够理解的语义数据网络,在此基础之上构建更加智能的应用。
- ◆ 目前,实现该设想的最大项目是2007年提出的LOD(Linked Open Data)。
- ◆ 至今,LOD中已经包含了1000多个数据集。

## 4. 链接数据(2007年起)

- ◆ 自从实践数据链接开始,
  - ▶ 在技术层面,语义web开始弱化"语义推理"的功能,而更强调"Web"的作用,即侧重数据的互联互通,因此Linked Data可以看作是语义Web的一个简化集合。
  - ▶ **在实现层面**, Linked Data 提倡使用RDF三元组形式描述知识,很少使用理论 更完备的OWL系列方法,降低了实现数据链接的技术难度。
- ◆ 自此,语义Web开始进入"弱语义"的阶段,语义Web的体系结构开始向知识图 谱过渡发展。
- ◆ "弱语义"是指: 只强调词与词之间存在的语义关系,而不再强调知识库整体的语义完整性。

## 5. 知识图谱的正式提出(2012年)

- ◆ 2012年5月17日,Google 正式提出了知识图谱的概念,发布了称之为"知识图谱"的项目,其初衷是为了优化其搜索引擎返回的结果,增强其搜索引擎的信息检索能力,提高用户搜索质量及体验。
- ◆ 知识图谱项目旨在将互联网中所有不同类型、不同语言的信息连接在一起,从这 些海量数据资源中提取实体、属性以及实体之间的关系,并利用这些信息构建知 识的语义网络,实现更加智能的存储、管理和检索知识功能。
- ◆ 知识图谱进一步弱化了语义,仅保留了RDF三元组的基本形式,将知识表示为图 结构的数据。
- ◆ 这种简单的形式非常适合于知识的自动化生成,降低了工程实践的难度,促进了应用的推广。

# 2. 5. 4 典型的知识图谱

从早期**人工构建的知识库**发展到如今**自动构建的知识图谱**,其间大致可以划分为"强语义"和"弱语义"阶段。

- ◆ "强语义"阶段的典型知识库(从1960年代到2006年) 重点研究如何建立语义表示体系,依赖于专家制定、人工添加、合作编辑的模式构建 知识库。典型知识库应用有: Cyc、WordNet、HowNet和ConceptNet。
- ◆"弱语义"阶段的典型知识图谱

进入互联网时代后,搜索引擎成为获取信息的主要手段,人们更多关注的是"是否存在某种知识,且能否找到某种知识",而不是"是否可以理解、推理某种知识"。显然,使得知识库越来越倾向于"弱语义、大规模"的趋势,不再强调逻辑复杂的语义及其推理,而是强调如何利用互联网知识自动构建大规模知识图谱。

## 1. "强语义"阶段的典型知识库 (1) 1984年, CYC 知识库

- ◆ CYC是1984年创建的,并延续至今,是目前**持续时间最长**的知识库项目。
- ◆ CYC 中的知识主要是通过手工添加的,类似定理库。
- ◆ 知识主要由"术语/概念"和"断言"组成。知识既包括事实,又包括规则。
- ◆ 典型的常识知识: "每棵树都是植物"、"植物最终都会死亡"。
- ◆ 这些知识是以一阶谓词逻辑的形式存储的。
- ◆ CYC不仅包括知识,还包括许多推理引擎,支持演绎推理和归纳推理。
- ◆ CYC的主要特点是采用形式化的知识表示方法来刻画知识,
- ◆ CYC的优点: 推理效率很高,可以支持复杂推理。
- ◆ CYC的缺点: 手工构建成本高,知识更新慢,形式化也导致知识库的可扩展性差、 推理不灵活、适应性不强。
- ◆ 近几年,CYC开始通过机器学习来自动获取知识。
- ◆ 官网(https://www.cyc.com/) 还提供了免费的版本OpenCYC。

## (2) 1985年, WordNet

- ◆ WordNet是典型的语义网络,1985年开始构建,最初的目的是用于多义词的词义消歧。
- ◆ WordNet是目前知名度最高的词典知识库,它主要依靠语言学家定义名词、动词、形容词和副词之间的语义关系。
- ◆ 每个词(word)可能有多个不同的语义(sense),WordNet 将语义相近的词集中在一组,称为一个 Synset(同义词集合),具有多个语义的词将出现在多个 Synset 中。
- ◆ WordNet为每一个Synset 提供了简短、概要的定义,并记录了不同 Synset 之间的语义 关系。
- ◆ WordNet的规模不断增长,WordNet 3.0中包括15万个词和20万条语义关系,已成为目前语义分析的重要工具,被广泛应用于语义消歧等自然语言处理领域。

### WordNet 的特点

◆ 优点:早期的WordNet是利用相关领域专家提供的知识、由人工构建的,具有很高的准确率和利用价值。

#### ◆ 缺点:

- ◆ 其构建过程耗时耗力,且存在覆盖面较小的问题。
- ◆ 它没有考虑特定语境下相关概念之间的联系。
  - ▶ 例如,WordNet 中没有将网球拍、网球、球网等词语以联系到一起。这就是著名的"tennis problem"(网球问题)。
  - ▶ 网球问题涉及许多知识的描述和关联,也是目前通用人工智能亟待解决的问题之一。

## (3) 1999年, ConceptNet

- ◆ ConceptNet 知识库最早源于1999年,由明斯基创建的 Open Mind Common Sense 项目。
- ◆ ConceptNet 最初的目标:构建一个描述人类常识的大型语义Web。
- ◆ ConceptNet 采用RDF三元组形式表示知识,而非谓词逻辑。
- ◆ ConceptNet 不再完全由专家来制定结构、层级、语义体系,而是引入了互联网众包和互联网挖掘的方式,属于半自动、半人工的构建方式。
- ◆ ConceptNet中的所有概念都来自于真实文本,概念之间的关系可根据文本的统计数据确定。
- ◆ 这种从文本中自动抽取的关系并不是由专家事先制定好的,它只强调词与词之间存在的关系,而不再强调知识库整体的语义完整性。这表明ConceptNet 已向"弱语义"知识库过渡。

## (4) 1988年, 知网 (HowNet)

- ◆ 前面三个知识库均以英文为主。
- ◆ 近几年也开始扩展到中文,如 wordnet、conceptnet 都已经加入了中文词汇。
- ◆ 知网, 意为知识网络, 1988年由中科院的董振东先生提出。
- ◆ 知网是一个以汉语和英语的词语所代表的概念为描述对象,以揭示概念与概念之间以 及概念所具有的属性之间的关系为基本内容的常识知识库。
- ◆ 知网是一个**网状结构**的知识系统,采用自下而上的、归纳的建设方法。
- ◆ 在知网的知识体系中,最基本的、不易于再分割的最小语义单位称为义原(Sememe)。
- ◆ **义原**是由人类专家通过大量阅读文本、逐步精炼而人工得到的,进而再用义原标注、解释事件和概念,然后加入概念、属性之间的关系,构成网络。
- ◆ HowNet 还在持续发展中,目前也已经有公开版本 OpenHowNet 问世。

## 2. 弱语义阶段的典型知识图谱

- ◆ 进入互联网时代后,许多学者开始尝试利用机器学习、信息抽取等技术 自动从互联网获取词汇知识。
  - ▶ 华盛顿大学的TextRunner(现改为OpenIE,开放信息抽取系统)。
  - ▶ 卡内基梅隆大学的NELL (Never-Ending Language Learning)
- ◆ 这些系统不需要手工标注,而是完全利用算法,以互联网网页上的文本 为知识源,自动分析、发现其中的概念以及概念之间的关系。
- ◆ 优点: 很容易获得大量知识。
- ◆ 缺点: 虽然互联网上信息量庞大,但知识密度很低,且信息质量良莠不 齐, 获取知识的准确率和效率均比较低。

## 另一条路: Wikipedia

- ◆ 若想自动构建高质量的知识库,必须 具有知识密集、格式统一、大规模的 知识源。
- ◆ 2010年前后,随着在线百科网站的兴起,这种知识源逐渐成熟,其中最著名的就是众所周知的**维基百科**,Wikipedia。



## 在线百科全书 Wikipedia

- ◆ 维基百科是一个网络百科全书式的多语言知识库,其特点:可自由添加内容、自由 编辑词条。
- ◆ 它以互联网和Wiki技术(即支持社群协同写作的一种超文本技术,还包括一组支持 这种写作方式的辅助工具)为媒介,由全球各地的志愿者们合作编撰而成。
- ◆ 每个词条包含用相应语言描述的**实体、概念及其属性、属性值信息**。
- ◆ 目前维基百科一共有285种语言版本,其中英语、德语、法语、荷兰语、意大利语、 波兰语、西班牙语、俄语、日语版本已有超过100万篇条目,中文和葡萄牙语版本 有超过90万篇条目。
- ◆ 维基百科等在线百科网站为知识图谱的自动构建奠定了基础。
- ◆ 目前,大多数通用的知识图谱均是通过对维基百科进行自动分析构建的。

# 基于在线百科的知识图谱

- ◆ 从 Freebase 到 Wikidata
- ◆ Dbpedia
- **♦** YAGO
- **♦** BabelNet

## (1) 从 FreeBase 到 Wikidata

- ◆ 2005年,由MetaWeb公司启动的Freebase 是一个开放共享、协同构建的大规模链接知识库,是语义Web应用项目。
- ◆ 其主要数据来源包括维基百科、世界名人数据库、开放音乐数据库,以及社区用户的贡献等。
- ◆ 早期的 FreeBase 由人工提取知识,将其构建为 Freebase 格式的三元组形式。
- ◆ Freebase是典型的"弱语义"知识库,它对知识库中的实体和关系不做严格的控制, 完全由用户来创建、编辑。
- ◆ 2010年,谷歌收购了MetaWeb公司,将Freebase作为其知识图谱的重要数据来源, 并于2012年发布谷歌知识图谱。

### (1) 从 FreeBase 到 Wikidata

- ◆ 2015年5月,谷歌将Freebase 的数据和API服务整体迁移至Wikidata,并于2016年5月 正式关闭了Freebase服务。
- ◆ Wikidata 改进了 Freebase 的结构,以提高数据的质量,并与 Wikipedia 深度结合。
- ◆ Wikidata继承了Wikipedia的众包协作机制。
- ◆ Wikidata与Wikipedia 不同的是: Wikidata 支持以事实三元组为基础的知识条目编辑。





## (2) DBpedia

- ◆ 2007年,建立了DBpedia,它是一个基于维基百科的语义Web应用项目。
- ◆ DBpedia 旨在将Wikipedia中的知识系统化、规范化、结构化,以提升维基百科的搜索功能。DBpedia可看成是数据库版本的Wikipedia,是从 Wikipedia中抽取出来的链接数据集。
- ◆ 此外,DBpedia 还是LOD (Linked Open Data)计划的核心,与 Freebase,OpenCYC、Bio2RDF 等多个数据集建立了数据链接。
- ◆ DBpedia是目前已知的第一个大规模开放域链接数据。而且DBpedia还能自动与维基百科保持同步,覆盖多种语言。
- ◆ 与Freebase不同,**DBpedia定义了一套较为严格的语义体系**,采用 **RDF**三元组语义 数据模型。

### (3) YAGO

- ◆ YAGO 是由**德国马普**研究所研制于 2007 年开始构建的多语言知识图谱,主要集成了Wikipedia、WordNet 和 GeoNames三个来源的数据。
- ◆ YAGO的特点:将WordNet的词汇定义与Wikipedia的分类体系进行了知识融合,构建了一个复杂的、丰富的实体分类层次体系。
- ◆ YAGO 还考虑了时间和空间知识,为很多知识条目增加了时间和空间维度的属性描述。
- ◆ 值得一提的是,YAGO 是 IBM Watson 的后端知识库之一。

#### (4) BabelNet

- ◆ BabelNet是于2013年开始创建的,其功能类似于WordNet,是一个多语言百科全书 式的字典和大规模语义网络。
- ◆ BabelNet特点:以自动映射的方式,将WordNet词典与Wikipedia多语言百科全书进行链接整合;而且借助统计机器翻译来补充,解决了WordNet 中小语种资源缺乏的问题。
- ◆ BabelNet 核心思想: Wikipedia中的许多词条都具有多语言版本,因此,如果在 Wikipedia中能找到与WordNet中的某词条相匹配的条目,则相当于**为WordNet的该** 词条提供了多语言的版本。
- ◆ BabelNet 4.0版本是目前最大规模的多语言词典知识库。

## 中文知识图谱

- ◆ 迄今为止,知识图谱的研究与应用在发达国家已逐步拓展并取得了较好的效果,但 在我国仍处于起步阶段。
- ◆ 因此,中国中文信息学会语言与知识计算专业委员会于2015年发起和倡导了开放知 识图谱社区联盟(OpenKG.cn)项目。
- ◆ OpenKG是公益性中立项目,旨在推动基于中文的知识图谱数据的开放、互联与众包, 以及知识图谱算法、工具和平台的开源开放工作。
- ◆ 近些年,以中文为主语言的知识图谱主要是基于百度百科和维基百科的结构化信息构建起来的,如哈尔滨工业大学的"大词林"、上海交通大学的"zhishi.me"、清华大学的"XLore"及复旦大学的"CN-pedia"等。

## 2.5.5 知识图谱的应用

- ◆ 知识图谱为互联网上**海量、异构、动态的大数据**提供了一种更有效的表示、组织、 管理及利用的方式,更加接近于人类的认知思维。
- ◆ 知识图谱已成为知识驱动的智能应用的基础设施,且已在许多领域中有了较为成功的应用。例如: 语义搜索、知识问答、社交网络方面的应用。
- ◆ 此外,知识图谱还应用于**大数据分析与决策、推荐系统**以及一些**垂直行业**(教育、 医疗、金融风险控制等)中,成为支撑这些应用发展的动力源泉。
- ◆ 目前,基于知识图谱的服务与应用已成为当前的研究热点,知识图谱与大数据、深度学习相结合,也已成为推动互联网和人工智能发展的核心驱动力之一。

## 知识图谱的应用1: 语义搜索

- ◆ 传统的信息搜索方法是基于关键词的搜索。这种方式往往无法理解用户的意图,而 是直接将包含关键词的若干页面返回给用户,还需要用户自己再次甄选,获取有用 的信息。
- ◆ 构建知识图谱的初衷:提升搜索引擎的性能,优化搜索结果,改善用户的搜索体验, 这就是"**语义搜索**"。
- ◆ 语义搜索将知识图谱引入搜索引擎后,利用其有良好定义的结构化语义知识和推理 技术,可以从用户输入的关键词中发现其深层含义,从而为用户返回更精确的搜索 结果。
- ◆ 利用知识图谱搜索,所返回结果的展现形式称为<mark>知识卡片</mark>,旨在为用户提供更多的 与搜索内容相关的信息。

## 知识图谱的应用: 百度语义搜索的例子



山东省省会

10

根据输入信息, 理解语义

并直接给出"知识卡片"

百度一下

阿丁页 资讯 贴吧 知道 视频 音乐

地图 文库 更多»

百度为您找到相关结果约22,400,000个



山东省会:

济南市 (山东省)

济南市,简称"济",别称"泉城",山东省省会、全国十五个副省级城市之一,解放军五大战区之一的北部战区陆军机关驻地,是山东政治、文化、教育中心,济南因境内泉水众... 详情>>

图片

来白百度百科

#### 济南为什么是山东省的省会城市?



历史上临淄、青州曾经是山东区域的政治中心之一。自明朝以后,济南 成为<mark>山东省会</mark>且延续至今。 历史文化因素 济...

→ 飞叔上 - - 百度快盟

#### 山东省最知名的两个城市,一个是省会,一个最有钱,你更喜欢哪个



2018年4月12日 - 提到山东省比较出名的城市,大家自然而然就会想到 济南和青岛吧,毕竟济南是山东省的省会城市,而青岛则是山东省……

₹ 一影讲世 ▼ - 百度快照

#### 做过山东省会的四座城市,除了济南,还有哪三座?



2018年2月25日 - 山东正式设省是在明朝时期,自山东省设立,共有四座 城市做过山东省省会。 青州,古九州之一,历史上长时间为...

● 沧海桑田史海沉約 - 百度快照

根据检索词,寻找相关词、 相关知识

#### 相关词汇



当份中国的行政

柳柳



地方虽小却很重要



城市群 大部市区的 联合体



展开 >

度 毎平方公里 平均人口数

#### 相关地名



广西省全 广西壮族自 治区



山东烟台 中国重要的 黄金产地



山东省行政 区划 山东地区行

政区域划公



东北三省 新中国的工 业概题

展开 >

#### 山东省地名



济宁

临沂地区

74 機数区 75

历下区

山东 百度百科

## 知识图谱的应用2:知识问答

- ◆ 问答(Question Answering, QA)系统指让计算机以准确、简洁的自然语言自动回答用户所提出的问题,是信息检索的一种高级形式。
- ◆ 不同于现有的搜索引擎,问答系统返回给用户的不再是若干相关文档,而是精准的、 单一的语言形式的答案。
- ◆ 2011年, IBM Watson 在智力竞赛节目 "Jeopardy!" 中战胜了人类选手而夺冠,引起了巨大轰动。
- ◆ 不过,在当时,问答系统的核心技术**仍以"检索"为主**,即**在大规模知识库中直接** 搜索答案。
- ◆ 近几年,随着知识图谱规模的扩大和技术的成熟,研究者开始利用知识图谱来回答问题,即"知识问答"。

## 知识图谱的应用2:知识问答

- ◆ 知识问答实现过程分为两步:
  - (1) 分析用户所提的问题:对问句进行语义分析,提取问句的语义单元,区分涉及的"实体"和要问的"关系",将用户问题解析为知识图谱中已定义好的实体、关系,即将非结构化的问句解析为可用三元组推理的结构化"查询";
  - (2) 推理出答案:将该"查询"与知识图谱中的三元组进行匹配、检索或推理,返回正确的答案。
- ◆ 在后续几年,各大IT巨头相继推出以问答系统为核心技术的产品和服务,如 Siri、Cortana、百度小度等。

## 知识图谱的应用3: 社交网络

- ◆ 2013年1月,Facebook公司推出了一款社交搜索产品"图谱搜索",其核心技术就是采用知识图谱将人、地点、事情等联系在一起,并以直观的方式支持精确的自然语言查询。
- ◆ 知识图谱会帮助用户在庞大的社交网络中找到与自己最具相关性的人、照片、地点和兴趣等。
- ◆ 在**传统的搜索**中,搜索对象是网页,搜索引擎根据热门程度确定返回的若干相关网页的链接在搜索结果中的显示顺序。
- ◆ "图谱搜索"搜索的对象不是网页,而是不断壮大的社交图谱,并以好友联系的频率、朋友们去过的地点、点赞次数及评价等数据作为依据,通过语义识别,直接为用户提供满足个性化需求的答案,这个答案可以是视频、图片、地点等一切和用户需求相关的结果,而不仅仅是冰冷的链接。

## 2.6 本章小结

#### 1. 知识和知识表示

知识、知识的特性、知识的分类、知识表示、知识表示方法的分类

#### 2. 产生式表示

产生式、产生式的分类、产生式系统的组成、产生式表示法的主要优点和缺点

#### 3. 状态空间的知识表示法

状态空间、状态空间的解、状态空间图

#### 4. 知识图谱

知识图谱的定义、三元组表示形式